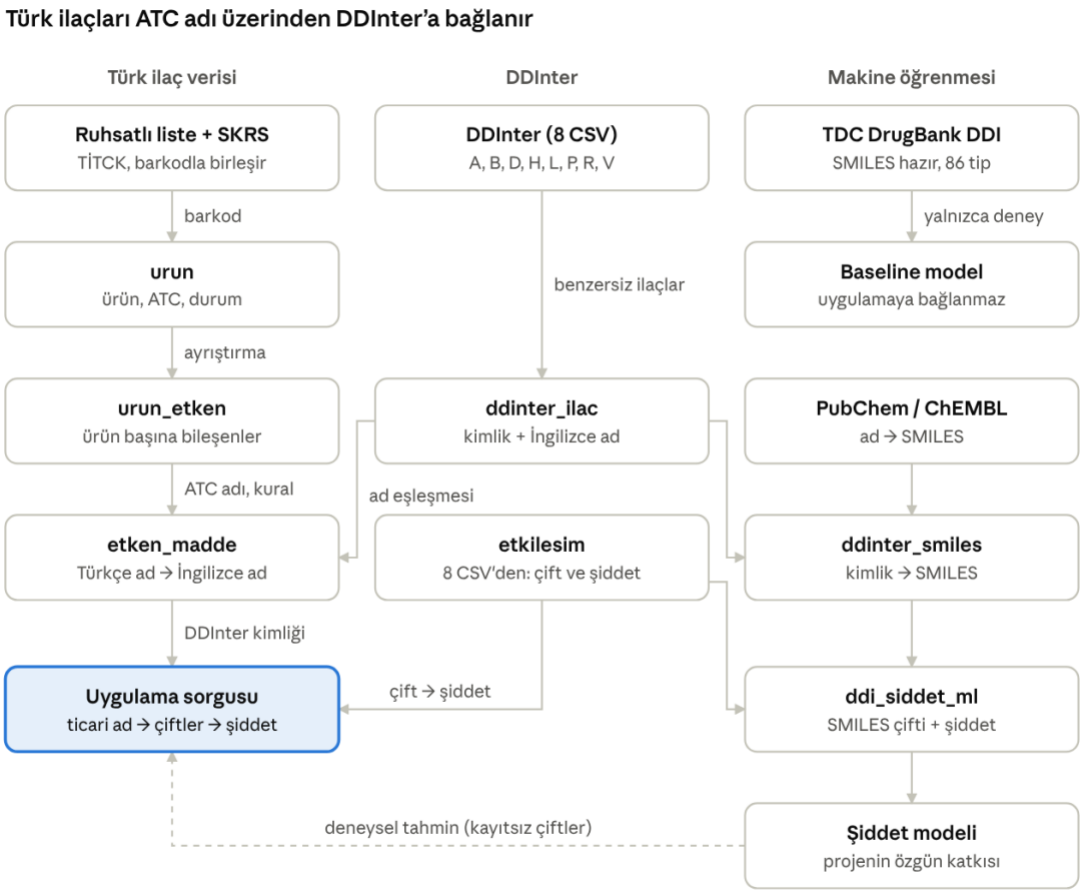
Veri Birleştirme Planı ve 2. Hafta Görevleri

Uygulama, TİTCK ve SKRS listelerinden gelen Türk ilaç bilgisini ATC kodu üzerinden DDInter'a bağlayarak çalışır; makine öğrenmesi tarafı ise TDC DrugBank ve SMILES eklenmiş DDInter verisini kullanır. Bu belge hangi verinin hangi anahtarla birleşeceğini, 2. haftada yapılacak her işi ve EDA'da çizilecek her grafiği tanımlar.

Veri hattı



veri hattı · 3 kol, 14 kutu

Sol kol uygulamanın kullandığı Türk ilaç tablolarını, orta kol DDInter tablolarını gösterir; ikisi `etken_madde` ile `ddinter_ilac` arasındaki İngilizce ad eşleşmesinde buluşur. Sağ kol makine öğrenmesidir: TDC DrugBank yalnızca deneyde kalır, şiddet modeli ise kayıtlı olmayan çiftler için uygulamaya deneysel tahmin verir.

Kullanılacak veriler ve sabit kurallar

Aşağıdaki altı kaynak kullanılır; listede olmayan hiçbir veri projeye alınmaz. Kurallar danışman kararıdır; bir durum kurallara uymuyorsa varsayımda bulunulmaz, `docs/acik_sorular.md` dosyasına yazılıp toplantıda sorulur.

Veri	Dosya / erişim	Projedeki rolü	Birleştirme anahtarı
TİTCK Ruhsatlı Beşeri Tıbbi Ürünler Listesi	XLSX, ana sekme	Ana ilaç listesi	Barkod
SKRS E-Reçete Listesi	XLSX, Aktif ve Pasif sekmeleri	Durum, İngilizce ATC adı	Barkod
DDInter	8 CSV (A, B, D, H, L, P, R, V)	Uygulamanın etkileşim ve şiddet verisi	İngilizce etken madde adı → DDInter kimliği
PubChem (yedek: ChEMBL)	Web API	DDInter ilaçlarına SMILES	İlaç adı
TDC DrugBank DDI	`tdc.multi_pred.DDI(name='DrugBank')`	Baseline model	Birleştirme yok
TDC TWOSIDES	`tdc.multi_pred.DDI(name='TWOSIDES')`	İsteğe bağlı ikinci benchmark	Birleştirme yok

Kullanılmayacaklar: Kaggle DrugBank seti, nSIDES dosyasındaki A, B, C, D ve PRR sütunları (model girdisi olarak), ilaç–besin PDF'i, Drugs.com / Medscape / BNF / RxMediaPharma'dan veri çekme.

Sabit kurallar

1. **Ana kaynak:** Ürün adı, etkin madde ve ATC için Ruhsatlı Liste esas alınır. SKRS yalnızca durum (aktif/pasif), reçete türü ve ATC Adı için kullanılır.
2. **Barkod temizliği:** Baş/son boşluk ve basılabilir olmayan karakterler atılır; 13 haneli olmayan veya EAN-13 sağlama hanesi tutmayan barkodlar silinmez, `barkod_gecersiz=1` ile işaretlenir.
3. **Tekrar eden barkod:** Aynı barkodlu satırlardan ruhsatı askıda olmayan ve ruhsat tarihi en yeni olan tutulur; diğerleri `barkod_tekrar.csv` dosyasına yazılır.
4. **Kapsam dışı bayrağı:** ATC'si V06 veya V07 ile başlayanlar ve B05 ile başlayıp 5 ya da daha fazla bileşeni olanlar `kapsam_disi=1` olur. Bu satırlar silinmez, etkileşim analizine girmez. Tek bileşenli elektrolitler (ör. potasyum klörür) kapsam içindedir.
5. **SKRS'te aktif olup ruhsatlıda olmayan ürünler:** Kapsam dışı bayrağı almayanlar tabloya eklenir; etkin madde olarak SKRS ATC Adı yazılır (bu metin zaten İngilizce olduğu için bu ürünler Adım 2'deki Türkçe temizlikten geçmez: bileşenleri ATC adından " and " ile bölünerek alınır ve Adım 3'te doğrudan ad_en olarak kaydedilir, yol='SKRS'), `kaynak='SKRS'` işaretlenir.
6. **Boş kayıtlar:** Etkin maddesi veya ATC'si boş olan ürünler barkodla SKRS'ten tamamlanır; etkin madde yerine SKRS'in İngilizce ATC adı geldiği için bu ürünler de kural 5'teki gibi işlenir (yol='SKRS'). Tamamlanamayanlar `eksik_kayit.csv` dosyasına yazılır ve analizden çıkar.
7. **Tuz ve hidrat ekleri:** Eşleme için ana etken maddeye indirgenir; orijinal metin `etkin_madde_ham` sütununda korunur.

8. **ATC çelişkisi:** Kodlardan biri diğerinin başlangıcıysa uzun (daha ayrıntılı) kod alınır. Gerçekten farklıysa ruhsatlı kod alınır, `atc_celiski=1` işaretlenir ve bu ürün ATC köprüsü yerine etkin madde metniyle eşlenir.
9. **DDInter tekrarları:** A–B ve B–A aynı kayıttır. Aynı çift farklı şiddetlerle geçiyorsa sıralama Major > Moderate > Minor > Unknown olacak şekilde en yüksek şiddet alınır ve `siddet_celiski=1` işaretlenir.
10. **Unknown şiddeti:** Uygulamada "Şiddeti belirtilmemiş etkileşim" olarak gösterilir. EDA'da ayrı sınıf olarak raporlanır. Modele dahil edilip edilmeyeceğine 3. haftada karar verilir.
11. **Hiçbir satır silinmez:** Ham dosyalar `data/raw/` altında değişmeden kalır; temizlik adımları bayrak sütunu ekler ve atlanan satırlar ayrı CSV'ye yazılır.

Birleştirme adımları

Adımlar 1–5 uygulamanın veri tabanını, adım 6–7 makine öğrenmesi verisini üretir. Örneklerdeki barkodlar ve DDInter kimlikleri temsilidir (`8699…`, `DDInter…`); gerçek değerler dosyalardan gelir. İlaç adları ve ATC kodları gerçektir.

Adım 1 – Ruhsatlı liste + SKRS → `urun`

- **Girdi:** Ruhsatlı liste (ana sekme), SKRS Aktif ve Pasif sekmeleri
- **Anahtar:** Temizlenmiş barkod
- **Birleştirme:** Ruhsatlı listeye SKRS soldan birleştirilir (left join). SKRS'te aktif olup ruhsatlıda olmayanlar ayrıca eklenir (kural 5).
- **Çıktı:** `data/interim/urun.csv`

barkod	urun_adi	etkin_madde_ham	atc_ruhsat	atc_skrs	atc_adi_skrs	durum	kaynak
8699…001	ARVELES 25 MG FILM KAPLI TABLET	deksketoprofen trometamol	M01AE17	M01AE17	dexketoprofen	Aktif	Ruhsatlı
8699…002	COUMADIN 5 MG TABLET	varfarin sodyum	B01AA03	B01AA03	warfarin	Aktif	Ruhsatlı
8699…003	KLACID 500 MG FILM KAPLI TABLET	klaritromisin	J01FA09	J01FA09	clarithromycin	Aktif	Ruhsatlı
8699…004	(örnek kombine ürün)	amlodipin besilat + valsartan	C09DB01	C09DB01	valsartan and amlodipin	Aktif	Ruhsatlı

barkod	urun_adi	etkin_madde_ham	atc_ruhsat	atc_skrs	atc_adi_skrs	durum	kaynak
					e		

Adım 2 – Etkin maddenin bileşenlere ayrılması → `urun_etken`

- Ayırıcılar sırayla denenir: `+`, `/`, ve, and, `;`. Virgül yalnızca iki tarafında da harfle başlayan ve en az 4 harfli bir sözcük varsa ayırıcı sayılır; ayrıştırılamayanlar `ayristirma_kontrol.csv` dosyasına yazılır.
- Küçük harfe dönüşüm Türkçe kurala göre yapılır (`İ → i`, `I → ı`); ardından çift boşluk tek boşluğa indirilir. Bu dönüşüm yalnızca Türkçe etkin madde metnine uygulanır; İngilizce adlar (ATC adı, DDInter adları) standart küçük harfe çevrilir. Ticari ad aramasında ise hem ürün adı hem kullanıcının yazdığı metin aynı biçimde katlanır: ı ile i, İ ile I aynı harf sayılır. Aksi halde "KLACID" Türkçe kuralla "klacıd" olur ve "klacid" araması onu bulamaz.
- Tuz ve hidrat sözcükleri bir liste ile atılır: sodyum, potasyum, kalsiyum, hidroklorür, hcl, besilat, maleat, trometamol, fumarat, sülfat, dihidrat, monohidrat, anhidr, anhidrat vb. Sözcükler alt dize olarak değil, tam sözcük olarak atılır; örneğin "anhidr" kuralı "anhidrat" sözcüğünden geriye "at" bırakmamalıdır. Liste `config/tuz_listesi.txt` dosyasında tutulur.
- **Dikkat:** Tuz sözcüğü etken maddenin kendisiyse (ör. "potasyum klörür", "sodyum klörür") atılmaz. Kural: sözcük atanca geriye hiçbir şey kalmıyorsa ya da yalnızca "klörür" gibi bir anyon kalıyorsa orijinal metin korunur.
- **Çıktı:** `data/interim/urun_etken.csv` (bir ürün için bileşen sayısı kadar satır)

barkod	sira	bilesen_ham	bilesen_tr
8699…001	1	deksketoprofen trometamol	deksketoprofen
8699…002	1	varfarin sodyum	varfarin
8699…003	1	klaritromisin	klaritromisin
8699…004	1	amlodipin besilat	amlodipin
8699…004	2	valsartan	valsartan

Adım 3 – Türkçe addan İngilizce ada köprü → `etken_madde`

Her benzersiz `bilesen_tr` için bir İngilizce ad bulunur. Yollar sırayla denenir; ilk başarılı yol kaydedilir.

1. **Yol A – Tek bileşenli ürün, 7 haneli ATC ve ATC çelişkisi yok (atc_celiski=0):** `atc_adi` (atc_final koduna göre sözlükten gelen ATC adı) doğrudan İngilizce addır (deksketoprofen → dexketoprofen). ATC adı ürünün kendi SKRS satırından değil, bir sözlükten alınır: SKRS'in tüm satırlarından (aktif + pasif) "ATC kodu → ATC adı" sözlüğü çıkarılır ve her ürüne ATC koduyla uygulanır. Böylece SKRS'te satırı olmayan ruhsatlı ürünler de bu yolu kullanabilir.
2. **Yol B – Kombine ürün, 7 haneli ATC ve ATC çelişkisi yok:** `atc_adi` metni `and` ve `,` ile bölünür. Parça sayısı Türkçe bileşen sayısına eşitse, parçalar Türkçe bileşenlerle yazım benzerliğine göre

eşlenir (ör. `rapidfuzz` ile; benzerlik ≥ 80). ("valsartan and amlodipine" → valsartan, amlodipine). ATC adı "combinations", "excl." veya "various" içeriyorsa (ör. "ibuprofen, combinations", "paracetamol, combinations excl. psycholeptics") metin bölünmez; bu ürünler Yol C ve D'ye gider.

3. **Yol C – Kural tabanlı çeviri:** Yol A ve B sonuç vermezse Türkçe ada kurallar uygulanır ve sonuç DDInter ad listesinde aranır. Kurallar `config/tr_en_kurallar.csv` dosyasında tutulur. Başlangıç kuralları: sondaki `-in` → `-ine` (amlodipin → amlodipine), `f` → `ph` (morfin → morphine), sondaki `-isin` → `-icin` (gentamisin → gentamicin). Kuralın sonucu DDInter ad listesinde birebir bulunmazsa Yol D'ye geçilir.
4. **Yol D – Elle eşleme:** Kalanlar `ruhsatli_esleme_taslagi.csv` dosyası üzerinden elle eşlenir. Elle eşleme, ürün sayısına göre en sık 300 etken madde için yapılır (2. haftada ilk 100'ü, kalanı 3. haftada); geri kalanı `eslesmedi` olarak kalır.

- **Çıktı:** `data/interim/etken_madde.csv`

bilesen_tr	ad_en	atc	yol	urun_sayisi
deksketoprofen	dexketoprofen	M01AE17	A	(dosyadan)
varfarin	warfarin	B01AA03	A	(dosyadan)
klaritromisin	clarithromycin	J01FA09	A	(dosyadan)
amlodipin	amlodipine	C08CA01	B	(dosyadan)
valsartan	valsartan	C09CA03	B	(dosyadan)

Adım 4 – İngilizce addan DDInter kimliğine → `etken_madde.ddinter_id`

- Önce 8 DDInter dosyasından benzersiz ilaç tablosu çıkarılır: `DDInterID_A, Drug_A` ve `DDInterID_B, Drug_B` alt alta eklenir, tekrarlar atılır. Çıktı: `data/interim/ddinter_ilac.csv` (yaklaşık 1.939 satır).
- Her iki tarafta ad normalize edilir: küçük harf, baş/son boşluk yok, tire ve çift boşluk tek boşluk.
- **Anahtar:** `etken_madde.ad_en` = `ddinter_ilac.ad_norm` (tam eşleşme).
- **Eşleşmeyenler için eş anlamlı kontrolü:** PubChem'den ilacın eş anlamlı adları çekilir ve DDInter adları içinde aranır (2. haftada ürün sayısına göre en sık 100 eşleşmeyen için, kalanı 3. haftada). Örnek: paracetamol DDInter'da Acetaminophen adıyla (DDInter14) geçer; tam ad eşleşmesi bunu bulamaz, eş anlamlı kontrolü bulur. PubChem isteği: `https://pubchem.ncbi.nlm.nih.gov/rest/pug/compound/name/paracetamol/synonyms/JSON`. Saniyede en fazla 5 istek gönderilir; yanıtlar `data/cache/pubchem/` altında saklanır, aynı istek tekrar gönderilmez.
- DDInter'da bulunmayan etken madde `ddinter_id = bos` olarak kalır; bu bir hata değil, raporlanacak bir sonuçtur.

Adım 5 – DDInter dosyalarının birleştirilmesi → `etkilesim`

- 8 CSV alt alta eklenir; her satıra `kaynak_dosya` sütunu (A, B, D…) eklenir.
- Her çift, kimliklerin sayısal kısmına göre sıralanır: küçük olan `id_1`, büyük olan `id_2` olur. (Metin sıralaması kullanılmaz; "DDInter1263" metin olarak "DDInter582"den küçük görünür.)

- Aynı `(id_1, id_2)` birden fazla kez geçiyorsa kural 9 uygulanır.
- **Çıktı:** `data/interim/etkilesim.csv`

Örnek (öğrencinin raporundaki gerçek satırlar):

Ham satır	id_1	id_2	siddet
DDInter1263 Naltrexone – DDInter1 Abacavir, Moderate	DDInter1	DDInter1263	Moderate
DDInter58 Aluminum hydroxide – DDInter582 Dolutegravir, Major	DDInter58	DDInter582	Major
DDInter582 Dolutegravir – DDInter273 Calcium citrate, Major	DDInter273	DDInter582	Major

Adım 6 – DDInter ilaçlarına SMILES → `ddinter_smiles` (makine öğrenmesi)

- **Girdi:** `ddinter_ilac.csv`
- **Anahtar:** İlaç adı → PubChem CID → SMILES. İstek biçimi: `https://pubchem.ncbi.nlm.nih.gov/rest/pug/compound/name/abacavir/property/SMILES/CSV`. `SMILES` özelliği stereokimya bilgisini de içerir; stereokimyasız sürüm `ConnectivitySMILES` adıyla alınır. PubChem eski `IsomericSMILES` ve `CanonicalSMILES` adlarını bu iki adla değiştirdi; eski adları kullanan hazır kodlarda sütun adı uyuşmazlığına dikkat edilir. PubChem'e erişilemezse ChEMBL API kullanılır. DDInter 2.0'ın ilaç sayfalarında da SMILES ve ATC bilgisi bulunur (ör. Acetaminophen, DDInter14); bu sayfalardan toplu veri çekilmez, yalnızca eşleşmeyen az sayıda ilacın elle kontrolünde kullanılır.
- Bir ad için birden fazla CID dönerse ilk CID alınır ve `coklu_cid=1` işaretlenir.
- SMILES bulunamayanlar (antikorlar, proteinler, aşılar, karma bitkisel ürünler) `smiles_yok=1` olarak işaretlenir ve modelden çıkar.
- SMILES nokta (`.`) içeriyorsa (tuz ya da çok parçalı molekül) RDKit ile en büyük parça tutulur.
- **Çıktı:** `data/processed/ddinter_smiles.csv` (ddinter_id, ad, cid, smiles, smiles_yok, coklu_cid)
- Ardından `etkilesim` tablosu bu tabloyla iki kez birleştirilir (`id_1` ve `id_2` üzerinden) ve `data/processed/ddi_siddet_ml.csv` oluşur: (smiles_1, smiles_2, siddet).

Adım 7 – TDC DrugBank DDI (makine öğrenmesi, birleştirme yok)

```
from tdc.multi_pred import DDI
from tdc.utils import get_label_map
data = DDI(name='DrugBank')
df = data.get_data()
label_map = get_label_map(name='DrugBank', task='DDI')
```

- Veri `data/raw/tdc_drugbank_ddi.csv` olarak bir kez kaydedilir; yeniden dağıtılmaz, depoya eklenmez (`.gitignore`).
- 86 tipin açıklamaları `data/interim/drugbank_tip_aciklama.csv` dosyasına yazılır.
- Bu veri uygulamaya bağlanmaz.

Uçtan uca örnek: Arveles + Coumadin + Klacid

Birinci haftada araç karşılaştırmasında kullanılan senaryo, uygulamanın ilk uçtan uca testi olarak da kullanılır. Kullanıcı üç ticari adı girer; sistem üç ikili çifti kontrol eder.

1. Kullanıcı girişi → etken madde → DDInter

Kullanıcı girişi	`urun` (adım 1)	`bilesen_tr` (adım 2)	`ad_en` (adım 3)	ATC	DDInter'da hangi dosyada aranabilir
Arveles	ARVELES 25 MG FILM KAPLI TABLET	deksketoprofen	dexketoprofen	M01AE17	M grubu dosyası yok; yalnızca partneri A, B, D, H, L, P, R, V grubundaysa bulunur
Coumadin	COUMADIN 5 MG TABLET	varfarin	warfarin	B01AA03	B dosyası
Klacid	KLACID 500 MG FILM KAPLI TABLET	klaritromisin	clarithromycin	J01FA09	J grubu dosyası yok; partneri mevcut gruplardaysa ya da DDInter klaritromisine A02BD (H. pylori kombinasyonu) kodunu da atadıysa bulunur

Arama kutusu `urun_adi` üzerinde çalışır. "Klacid" yazıldığında KLACID 500 mg film kaplı tablet ve KLACID MR 500 değiştirilmiş salımlı tablet gibi farklı ürünler listelenir; hepsi aynı etken maddeye (klaritromisin, J01FA09) çıkar.

2. İkili kombinasyonlar ve beklenen sonuç

Çift	ATC grupları	DDInter'da beklenen durum	Uygulamada gösterim
warfarin – clarithromycin	B + J	B dosyasında olması beklenir	DDInter'daki şiddet ve renk kodu
warfarin – dexketoprofen	B + M	B dosyasında olması beklenir (dexketoprofen DDInter'da varsa)	DDInter'daki şiddet ve renk kodu
dexketoprofen – clarithromycin	M + J	**Belirsiz**: iki ilacın ana grubu da indirilebilir dosyalarda yok; ancak DDInter bir ilaca birden fazla ATC kodu atayabilir (ör. Acetaminophen sayfasında 7 kod var). Klaritromisin A02BD kombinasyon kodlarında da yer aldığı için çift A dosyasında çıkabilir	"Bu çift için kayıt bulunamadı. Bu, etkileşim olmadığı anlamına gelmez." (Model hazır olduğunda: deneysel tahmin)

3. Kontrol

- Gerçek sonuçlar `docs/uctan_uca_test.md` dosyasına tablo olarak yazılır: her çift için bulundu/bulunmadı, şiddet, DDInter kimlikleri.
- Aynı üç çift Drugs.com ve Medscape etkileşim kontrol araçlarının sonuçlarıyla yan yana konur.
- "Beklenen" sütunu bir tahmindir. Gerçek sonuç farklıysa (ör. dexketoprofen DDInter'da hiç yoksa) bu da raporlanır; amaç tahmini doğrulamak değil, sistemin ne gösterdiğini kaydetmektir.

2. hafta: görev listesi

Bu haftanın hedefi, Türk ilaç listesinden DDInter'a uzanan zinciri ilk kez çalıştırmak ve "Türkiye'deki etken maddelerin yüzde kaçı için etkileşim verisi var?" sorusunu sayıyla cevaplamaktır. Görevler ekip olarak yapılır; sıra önemlidir çünkü her paket bir öncekinin çıktısını kullanır. Paketler hafta sonunda bitmiş olmalıdır; **zaman kalırsa** işaretli olanlar 3. haftaya devredilebilir.

İP0 – Çalışma ortamı ve klasör yapısı (ilk gün)

- ☐ Depoda şu klasörler açılır: `data/raw`, `data/interim`, `data/processed`, `data/cache`, `config`, `notebooks`, `src`, `figs`, `docs`
- ☐ `data/` klasörü `.gitignore` dosyasına eklenir; veriler depoya yüklenmez, indirme ve okuma kodu yüklenir

- ☐ Ham dosyalar indirme tarihiyle adlandırılır: `ruhsatli_2026-10-02.xlsx`, `skrs_2026-09-29.xlsx`, `ddinter_code_A.csv` … `ddinter_code_V.csv`
- ☐ `requirements.txt`: pandas, openpyxl, numpy, rapidfuzz, requests, matplotlib, seaborn, rdkit, PyTDC
- ☐ Ortak fonksiyonlar `src/normalize.py` dosyasına yazılır: `tr_lower()`, `barkod_temizle()`, `tuz_at()`, `ad_normalize()`. Notebook'larda aynı işlem tekrar yazılmaz, bu fonksiyonlar çağrılır
- ☐ Notebook adları numaralıdır ve sırayla çalışır: `01_titck_temizlik`, `02_etken_ayristirma`, `03_kopru_ddinter`, `04_ddinter_birlestirme`, `05_eda_titck`, `06_eda_ddinter`, `07_eda_tdc`, `08_smiles_pilot`
- **Bitti sayılır:** Başka bir ekip üyesi depoyu çekip `01` notebook'unu hatasız çalıştırabiliyor.

İP1 – TİTCK ve SKRS temizliği ve birleştirilmesi

- **Girdi:** Ruhsatlı liste, SKRS Aktif ve Pasif sekmeleri
- ☐ Tüm metin sütunlarında baş/son boşluk ve görünmez karakterler atılır (ATC dahil)
- ☐ Barkodlara kural 2 ve 3 uygulanır
- ☐ Ruhsatlı listeye SKRS barkodla soldan birleştirilir; SKRS'te aktif olup ruhsatlıda olmayanlar kural 5'e göre eklenir. Birleştirmeden önce SKRS'te barkod tekilleştirilir: aynı barkod hem Aktif hem Pasif sekmede varsa Aktif satır alınır. Aksi halde birleştirme satırları çoğaltır; birleştirmeden sonra ruhsatlı listenin satır sayısının artmadığı kontrol edilir
- ☐ Kural 4'ün V06/V07 kısmı ve kural 6 (boş kayıtlar) uygulanır. Kural 4'ün B05 ve 5+ bileşen kısmı bileşen sayısı belli olmadan uygulanamaz; İP2'nin sonunda uygulanır
- ☐ **ATC çelişkisi yeniden sayılır** (boşluk temizliğinden sonra) ve her çelişki bir sınıfa atanır:
  - `bosluk`: temizlikten sonra aynı kod
  - `duzey_farki`: biri diğerinin başlangıcı (ör. N02B ve N02BE01)
  - `ayni_grup_farkli_madde`: ilk 5 hane aynı, son 2 hane farklı
  - `farkli_grup`: ilk 5 hanesi farklı
  - `bos`: bir listede ATC yok
- ☐ `farkli_grup` sınıfından 20 rastgele ürün etkin madde metniyle elle kontrol edilir: hangi listedeki kod doğru? Sonuç `docs/atc_celiski_kontrol.md` dosyasına yazılır
- ☐ Kural 8 uygulanır; `atc_final` sütunu oluşur
- **Çıktılar:** `data/interim/urun.csv`, `data/interim/atc_celiski_siniflari.csv`, `barkod_tekrar.csv`, `eksik_kayit.csv`
- **Bitti sayılır:** Bir özet tablo var: başlangıç satır sayısı, eklenen SKRS ürünü, kapsam dışı işaretlenen, eksik kayıt, son satır sayısı; her ATC çelişki sınıfının sayısı.

İP2 – Etkin maddenin bileşenlere ayrılması

- **Girdi:** `urun.csv` (tüm satırlar; ayrıştırma kapsam dışı ürünlere de uygulanır, çünkü E01 ve kural 4'ün B05 kısmı bileşen sayısına ihtiyaç duyar; sonraki adımlar kapsam_disi=1 olanları atlar)
- ☐ "Birleştirme adımları" bölümündeki Adım 2 uygulanır
- ☐ `config/tuz_listesi.txt` oluşturulur; listeye eklenen her sözcük için en az bir örnek ürün yorum satırı olarak yazılır
- ☐ Kombine görünen ürünlerden 50'si rastgele seçilip elle kontrol edilir; doğru ayrıştırılanların oranı kaydedilir. Oran %90'ın altındaysa hatalı örneklere göre kural düzeltilip kontrol tekrarlanır

- ☐ Kural 4'ün kalan kısmı uygulanır: ATC'si B05 ile başlayıp 5 ya da daha fazla bileşeni olan ürünler `kapsam_disi=1` olur. Normalizasyon aşamalarının sayıları kaydedilir: ham benzersiz metin → küçük harf ve boşluk sonrası → tuz atıldıktan sonra → bileşenlere ayrıldıktan sonra benzersiz bileşen
- **Çıktılar:** `data/interim/urun_etken.csv`, `ayristirma_kontrol.csv`, `config/tuz_listesi.txt`
- **Bitti sayılır:** 50 ürünlük kontrolde doğruluk ≥ %90 ve normalizasyon aşamalarının sayıları tabloda.

İP3 – İngilizce ad köprüsü ve DDInter eşlemesi

- **Girdi:** `urun_etken.csv`, `urun.csv`, DDInter dosyaları
- ☐ `ddinter_ilac.csv` çıkarılır (Adım 4'ün ilk maddesi)
- ☐ Yol A ve Yol B tüm bileşenlere uygulanır
- ☐ Yol C, A ve B'den sonra kalanlara uygulanır
- ☐ Yol D (elle eşleme): ürün sayısına göre en sık **100** eşleşmemiş bileşen bu hafta; 100–300 arası zaman kalırsa
- ☐ DDInter'da tam ad eşleşmesi yapılır; eşleşmeyenlerin en sık 100'ü için PubChem eş anlamlı kontrolü yapılır
- ☐ Her bileşen için `yol` (A/B/C/D/SKRS/eslesmedi) ve `ddinter_id` kaydedilir
- **Çıktılar:** `data/interim/etken_madde.csv`, `docs/esleme_raporu.md`
- **Eşleşme raporunda olacak tablolar:**
  - Yol bazında bileşen sayısı (A, B, C, D, SKRS, eşleşmedi)
  - DDInter eşleşme oranı, iki şekilde: (1) benzersiz etken madde bazında, (2) ürün bazında (en az bir bileşeni DDInter'da bulunan ürünlerin oranı)
  - ATC ana grubuna göre DDInter eşleşme oranı (14 satır)
  - Eşleşmeyen en sık 30 bileşen ve ürün sayıları
- **Bitti sayılır:** "Türkiye'deki etken maddelerin %X'i, ruhsatlı ürünlerin %Y'si DDInter'da bulunuyor" cümlesi sayılarla yazılabiliyor.

İP4 – DDInter birleştirme ve kayıp analizi

- **Girdi:** 8 DDInter dosyası, `etken_madde.csv`
- ☐ Adım 5 uygulanır; `etkilesim.csv` oluşur
- ☐ Tekrar temizliğinden sonra yeniden sayılır: benzersiz ilaç, benzersiz çift, şiddet dağılımı, ilaç başına ortalama ve medyan eş sayısı, en çok etkileşen 20 ilaç. 1. hafta raporundaki tekrar öncesi sayıların yerine bunlar kullanılır
- ☐ Aynı çiftin farklı şiddetlerle geçtiği kayıt sayısı (`siddet_celiski`) raporlanır
- ☐ **Kayıp analizi:** DDInter'da bulunan Türk etken maddelerinin tüm olası ikili çiftleri üretilir. Her çift için iki maddenin ATC ana grubuna bakılır. İki madde de C, G, J, M, N veya S grubundaysa çift `kapsam_disi_grup` olarak işaretlenir. Bu çiftlerin tüm çiftlere oranı raporlanır. Bu bir yaklaşık hesaptır: kayıp, Türk listesindeki tek ATC koduna göre hesaplanır, oysa DDInter bir ilaca birden fazla ATC kodu atayabilir; gerçek kayıp daha düşük olabilir. 10 çiftlik web kontrolü bu yaklaşımın ne kadar tuttuğunu gösterir

- ☐ **Web kontrolü:** Aşağıdaki 10 çift DDInter'ın web sitesindeki etkileşim kontrol aracında elle aranır ve sonuç indirilen dosyalarla karşılaştırılır: dexketoprofen–clarithromycin, simvastatin–clarithromycin, amlodipine–simvastatin, ibuprofen–sertraline, digoxin–amiodarone, warfarin–clarithromycin, warfarin–dexketoprofen, ciprofloxacin–tizanidine, tramadol–sertraline, metformin–furosemide. Amaç, eksik grupların verisinin sitede olup olmadığını görmektir; siteden toplu veri çekilmez. DDInter 2.0 sitesinin indirme sayfası da aynı 8 dosyayı sunuyor, yani eksik gruplar orada da yok
- **Çıktılar:** `data/interim/etkilesim.csv`, `data/interim/ddinter_ilac.csv`, `docs/ddinter_kayip_analizi.md`
- **Bitti sayılır:** Tekrar sonrası sayılar, kayıp oranı ve 10 çiftlik web kontrolü tablosu hazır.

İP5 – TDC DrugBank hazırlığı

- ☐ Adım 7'deki kod çalıştırılır; veri ve 86 tip açıklaması kaydedilir
- ☐ SMILES'ı RDKit ile okunamayan ilaçlar sayılır ve listelenir
- ☐ Lisans durumu `docs/lisanslar.md` dosyasına eklenir: TDC'nin lisans metni, DrugBank'ın akademik indirmeleri durdurduğu bilgisi ve projede yalnızca akademik deney için kullanılacağı
- **Bitti sayılır:** `drugbank_tip_aciklama.csv` var ve EDA'da kullanılıyor.

İP6 – EDA

- ☐ "EDA planı" bölümündeki opsiyonel olmayan tüm grafikler çizilir ve `figs/` altına kaydedilir
- ☐ Her grafiğin altına `docs/eda_raporu.md` içinde 2–3 cümlelik yorum yazılır: ne görülüyor, sayı ne, projeye etkisi ne
- **Bitti sayılır:** EDA raporu opsiyonel olmayan tüm grafikleri ve yorumlarını içeriyor.

İP7 – Uçtan uca test (İP3 ve İP4'ten sonra)

- ☐ "Uçtan uca örnek" bölümündeki üç ilaç, uygulama henüz olmadığı için bir notebook fonksiyonuyla (`etkilesim_kontrol(['Arveles','Coumadin','Klacid'])`) test edilir
- ☐ Fonksiyon her çift için bulundu/bulunmadı, şiddet ve DDInter kimliklerini döndürür
- ☐ Aynı fonksiyon iki senaryo daha ile denenir: (1) kombine bir ürün içeren 3 ilaçlı bir liste, (2) en az bir ilacı DDInter'da bulunmayan bir liste
- **Çıktı:** `docs/uctan_uca_test.md`

İP8 – Araç testlerinin tekrarı

- ☐ Arveles–Coumadin–Klacid senaryosu yapay zekâ sohbet botlarıyla değil, sitelerin etkileşim kontrol araçlarıyla tekrarlanır: Drugs.com Drug Interaction Checker, Medscape Drug Interaction Checker (ücretsiz kayıtla), WebMD Drug Interaction Checker
- ☐ Her araç için aynı kayıt biçimi kullanılır:

Araç	Ticari ad tanındı mı	Etken madde ile giriş gerekti mi	Bulunan çiftler	Şiddet etiketi (araca özgü)	Açıklamanın özeti	Ekran görüntüsü dosyası

Araç	Ticari ad tanındı mı	Etken madde ile giriş gerekti mi	Bulunan çiftler	Şiddet etiketi (araca özgü)	Açıklamanın özeti	Ekran görüntüsü dosyası
Drugs.com						
Medscape						
WebMD						

- ☐ BNF testi danışman tarafından yapılacak; ekip aynı tablo sütunlarını BNF için boş bırakır
- ☐ RxMediaPharma için fakültenin veya üniversite hastanesi eczanesinin lisansı olup olmadığı sorulur; sonuç tabloya not olarak yazılır

İP9 – Literatür

- ☐ EmerGNN ve DDI-Ben, 1. haftadaki özet şablonuyla özetlenir. Özellikle şu sorular cevaplanır: Cold-start (yeni ilaç) senaryosu nasıl tanımlanmış? İlaçlar nasıl bölünmüş? Rastgele bölmeye göre performans ne kadar düşüyor? Not: EmerGNN yeni ilaç senaryolarını S1 (yeni ilaç – mevcut ilaç) ve S2 (iki yeni ilaç) olarak adlandırır; T06 grafiğindeki "biri yeni" ve "ikisi de yeni" senaryoları bunlara karşılık gelir ve raporda aynı adlar kullanılır.
- ☐ Literatür sonuç tablosu oluşturulur: makale, veri seti, bölme yöntemi (S0 rastgele / S1 bir ilacı yeni / S2 iki ilacı yeni), metrik, değer. 1. haftada okunan üç makale de tabloya eklenir

İP10 – SMILES pilotu (zaman kalırsa)

- ☐ `ddinter_ilac.csv` içinden rastgele 100 ilaç için Adım 6 denenir
- ☐ Raporlanır: kaç ilaçta SMILES bulundu, kaçı biyolojik/yok, kaçında birden fazla CID döndü, 100 istek ne kadar sürdü
- ☐ Bu oranla 1.939 ilacın tamamı için tahmini süre hesaplanır

İP11 – Kapsam kararı için hazırlık (toplantıdan önce)

- ☐ Birincil kullanıcı hasta/hasta yakını mı, eczacı mı? Tek sayfalık karşılaştırma hazırlanır: her seçenek için arayüz dili, şiddet gösterimi, uyarı metni gereksinimi, hangi kullanıcı hikâyelerinin öne çıktığı. Karar toplantıda verilir; ekip bir öneriyle gelir.

EDA planı

EDA üç soruya cevap verir: Türk ilaç verisi nasıl bir yapıda, bu verinin ne kadarı DDInter'a bağlanabiliyor ve model eğitilecek verinin sınıf ve ilaç dağılımı nasıl. EDA, temizlenmiş tablolar üzerinde yapılır (`data/interim/`); ham dosyalar üzerinde yapılmaz.

Genel kurallar

- **Önce özet tablo:** Her tablo için (`urun`, `urun_etken`, `etken_madde`, `ddinter_ilac`, `etkilesim`, TDC DrugBank) satır sayısı ve her sütun için veri tipi, boş değer sayısı, benzersiz değer sayısı, bir örnek değer. Tablo `docs/eda_raporu.md` içine yazılır.

- **Araçlar:** matplotlib ve seaborn. Her grafik `figs/<kod>_<kisa_ad>.png` olarak 300 dpi kaydedilir (ör. `figs/E09_ddinter_eslesme_atc.png`).
- **Eksenler:** Türkçe eksen başlıkları, birimiyle. Logaritmik ölçek kullanılan eksenin başlığında "(log)" yazar.
- **Değerler:** Çubuk grafiklerde sayılar çubuğun üstüne (yatay grafikte sağına) yazılır. Yüzde gösterilen her grafikte payda (n) da yazılır.
- **Sabit renkler (şiddet):** Major `#d62728`, Moderate `#ff7f0e`, Minor `#2ca02c`, Unknown `#7f7f7f`. Sıra her grafikte Major → Moderate → Minor → Unknown.
- **ATC grup adları:** Eksenlerde harf ve Türkçe ad birlikte yazılır (ör. "C – Kardiyovasküler").
- **DDInter'da dosyası olmayan gruplar** (C, G, J, M, N, S) ATC grubu olan her grafikte aynı biçimde işaretlenir: çizgili dolgu (`hatch='//'`) ve açıklamada "DDInter dosyası yok".
- **Her grafiğin yorumu:** Ne görülüyor (1 cümle), en önemli sayı (1 cümle), projeye etkisi (1 cümle).

A. Türk ilaç verisi (TİTCK + SKRS)

Kod	Grafik	Veri	x ekseni	y ekseni	Renk / ölçek	Cevaplanacak soru	Öncelik
E01	Çubuk	`urun_etken`, tüm ürünler (kapsam dışı dahil, çünkü 1. haftanın 4.572 tahmini de onları içeriyordu), barkod başına bileşen sayısı; kapsam dışı ürünler çubukta ayrı renkle	Bileşen sayısı (1, 2, 3, 4, 5, 6, 7+)	Ürün sayısı	y log	Tekli ve kombine ürün oranı ne? 1. haftanın kaba tahmininden (4.572 kombine) ne kadar farklı?	
E02	Yatay yığılmış çubuk	`urun`, `atc_final`'ın ilk harfi	Ürün sayısı	14 ATC ana grubu, toplama göre sıralı	Renk: SKRS durumu (aktif / pasif / SKRS'te yok); eksik	Ürünler hangi gruplarda yoğunlaşıyor? DDInter'da dosyası	

Kod	Grafik	Veri	x ekseni	y ekseni	Renk / ölçek	Cevaplanacak soru	Öncelik
					6 grup çizgili	olmayan gruplar ürünlerinin ne kadarını oluşturuyor?	
E03	Çubuk	`urun`, `atc_final` uzunluğu	Hane sayısı (1, 3, 4, 5, 7, diğer)	Ürün sayısı	—	Kaç üründe ATC yalnızca grup düzeyinde? Bu ürünler ATC köprüsünü kullanamaz	
E04	Çubuk (huni)	İP2'deki normalizasyon aşamaları	Aşama: ham metin → küçük harf ve boşluk → tuz atıldı → bileşenlere ayrıldı	Benzersiz etken madde sayısı	Değerler çubuk üstünde	Her temizlik adımı ne kadar indirgeme sağlıyor?	
E05	Yatay çubuk	`etken_madde`, ürün sayısına göre en sık 30 bileşen	Ürün sayısı	Bileşen adı (Türkçe)	Renk: DDInter'da var / yok	En çok kullanılan etken maddeler DDInter'da bulunuyor mu?	
E06	Histogram	`etken_madde.urun`	Etken madde	Etken madde	x log	Kaç etken madde	Opsiyonel

Kod	Grafik	Veri	x ekseni	y ekseni	Renk / ölçek	Cevaplanacak soru	Öncelik
		`_sayisi`	başına ürün sayısı (log, logaritmik aralıklar)	sayısı		tek bir ürünle temsil ediliyor? Elle eşlemede önceliklendirme bu dağılıma göre	
E07	Çubuk	`atc_celiski_siniflari`	Çelişki sınıfı (bosluk, duzey_farki, ayni_grup_farkli_madde, farkli_grup, bos)	Ürün sayısı	—	411 çelişkinin kaçı gerçek?	
E08	İki panelli çubuk	`etken_madde.yol`	Yol (A, B, C, D, SKRS, eşleşmedi)	Sol panel: benzersiz bileşen sayısı; sağ panel: bu bileşenleri içeren ürün sayısı	—	ATC köprüsü (Yol A ve B) eşlemenin ne kadarını tek başına çözüyor?	
E09	Çubuk	`etken_madde`, ATC ana grubu ve `ddinter_id`	14 ATC ana grubu	DDInter'da bulunan etken madde yüzdesi (0–100)	Eksik 6 grup çizgili; her çubuğun üstünde "%x (n=y)"	**En önemli grafik:** Hangi ilaç grupları için uygulama veri gösterebiliyor?	
E10	Çubuk	`urun` +	Aşama:	Ürün	Çubuk	Kullanıcını	

Kod	Grafik	Veri	x ekseni	y ekseni	Renk / ölçek	Cevaplanacak soru	Öncelik
	(huni)	`urun_etken` + `etken_madde`	kapsam içi ürün → tüm bileşenlerinin İngilizce adı var → en az bir bileşeni DDInter'da → tüm bileşenleri DDInter'da	sayısı	üstünde sayı ve ilk aşamaya göre yüzde	n arayabileceği ürünlerinin ne kadarı için tam sonuç verilebilir?	
E11	Çubuk	`urun`, SKRS reçete türü (aktif ürünler)	Reçete türü	Ürün sayısı	y log	Kontrollü reçeteli (kırmızı, yeşil, mor, turuncu) ürünlerin payı	Opsiyonel
E12	Histogram	`urun`, ruhsat tarihinin yılı	Ruhsat yılı	Ürün sayısı	Renk: ruhsatı askıda / değil	Listede eski ve askıdaki ürünlerin payı	Opsiyonel

B. DDInter

Kod	Grafik	Veri	x ekseni	y ekseni	Renk / ölçek	Cevaplanacak soru	Öncelik
D01	Gruplu çubuk	Ham 8 dosya ve `etkilesim`	Şiddet (Major, Moderate, Minor, Unknown)	Kayıt sayısı	Renk: ham / tekrar sonrası	Tekrar temizliği şiddet dağılımını değiştiriyor mu? (1. hafta raporundaki oranlar	

Kod	Grafik	Veri	x ekseni	y ekseni	Renk / ölçek	Cevaplanacak soru	Öncelik
						tekrar öncesiydi)	
D02	Yığılmış çubuk	Ham 8 dosya, dosya başına tekrarsız çift	Kaynak dosya (A, B, D, H, L, P, R, V)	Çift sayısı	Renk: şiddet	Hangi dosya ne kadar veri taşıyor; şiddet oranları dosyalara göre farklı mı? Not: bir çift iki dosyada birden geçebilir, bu yüzden çubukların toplamı benzersiz çift sayısından büyüktür	
D03	Histogram	`etkilesim`, ilaç başına farklı eş sayısı	Eş sayısı (log, logaritmik aralıklar)	İlaç sayısı	Ortalama ve medyan dikey kesikli çizgiyle	Kaç ilacın çok az kaydı var? Bu ilaçlar model için fiilen "yeni ilaç" sayılır	
D04	Yatay yığılmış çubuk	`etkilesim`, eş sayısına göre en çok etkileşen 20 ilaç	Çift sayısı	İlaç adı	Renk: şiddet	Kortikosteroid baskınlığı tekrar temizliğinden sonra da sürüyor mu?	

Kod	Grafik	Veri	x ekseni	y ekseni	Renk / ölçek	Cevaplanacak soru	Öncelik
D05	Isı haritası	`etkilesim`, yalnızca iki ilacı da Türk listesiyle eşleşen çiftler; ATC ana grubu `etken_madde`'den (birden fazla grup varsa en çok ürünlü olan)	İlaç 1'in ATC ana grubu (14)	İlaç 2'nin ATC ana grubu (14)	Hücre rengi: çift sayısı (log renk ölçeği); simetrik; sıfır hücreler beyaz	DDInter'ın eksik dosyaları hangi grup çiftlerinde boşluk yaratıyor? Eksik 6 grubun kendi aralarındaki hücrelerde çok az kayıt olması beklenir; bu hücreler boş değilse DDInter bu ilaçlara mevcut gruplardan da ATC kodu atamış demektir	
D06	Çubuk	İP4 kayıp analizi: DDInter'da bulunan Türk etken maddelerinin tüm olası çiftleri	Kategori: en az biri mevcut grupta / ikisi de eksik grupta	Olası çift sayısı	Çubuk üstünde yüzde	Türkiye'deki olası ilaç çiftlerinin yaklaşık yüzde kaçı indirilebilir DDInter verisiyle kontrol edilemiyor?	

Kod	Grafik	Veri	x ekseni	y ekseni	Renk / ölçek	Cevaplanacak soru	Öncelik
						(İP4'teki yaklaşık hesap)	
D07	Çubuk	`etkilesim` + ATC grubu	ATC ana grubu (çiftteki ilaçlardan herhangi biri)	Major çiftlerin yüzdesi	n çubuk üstünde	Hangi gruplarda ciddi etkileşim oranı daha yüksek?	Opsiyonel

C. TDC DrugBank DDI

Kod	Grafik	Veri	x ekseni	y ekseni	Renk / ölçek	Cevaplanacak soru	Öncelik
T01	Çubuk	Tüm 191.808 çift, `Y`	86 tip, çift sayısına göre azalan sırada	Çift sayısı	y log; 10, 50, 100 ve 300'de yatay kesikli çizgi; en sık 5 tipe `get_label_map` açıklaması etiket olarak	Sınıf dengesizliği ne kadar? Kaç tip 10'dan az örneğe sahip?	
T02	Gruplu çubuk	T01'in tip başına sayıları	Frekans grubu: [1,10], (10,50], (50,100], (100,300], (300,+∞)	Tiplerin yüzdesi	Renk: bizim hesap / MRCGNN makalesindeki Ryu oranları (%5,8 / %21,0 / %11,6 / %14,0 / %47,6)	TDC'deki veri, makaledeki Ryu verisiyle aynı dağılımı veriyor mu? Makaledeki oranlar 86 tipin yüzdesidir	

Kod	Grafik	Veri	x ekseni	y ekseni	Renk / ölçek	Cevaplanacak soru	Öncelik
						(sırasıyla 5, 18, 10, 12 ve 41 tip); bu nedenle T01'de 10'dan az örneği olan yaklaşık 5 tip görülmesi beklenir. TDC sürümündeki çift sayısı (191.808) makaledekinden (191.570) biraz farklı olduğu için küçük sapmalar normaldir	
T03	Histogram	Tüm çiftler, ilaç başına farklı eş sayısı	Eş sayısı (log, logaritmik aralıklar)	İlaç sayısı	Ortalama ve medyan dikey kesikli çizgiyle	D03 ile karşılaştırma: iki veri setinde ilaçların temsil düzeyi benzer mi?	
T04	Histogram	1.706 ilacın SMILES uzunluğu	Karakter sayısı (log)	İlaç sayısı	1.000 karakterde dikey çizgi	Çok uzun SMILES'lı (peptit benzeri)	

Kod	Grafik	Veri	x ekseni	y ekseni	Renk / ölçek	Cevaplanacak soru	Öncelik
						kaç ilaç var?	
T05	Histogram	RDKit ile molekül ağırlığı (`Descriptors.MolWt`)	Molekül ağırlığı (Da)	İlaç sayısı	900 Da'da dikey çizgi	Küçük molekül dışı kalan ilaç oranı	Opsiyonel
T06	Çubuk, hata çubuklu	İlaçlar rastgele %80 / %10 / %10 bölünür. İki ilacı da eğitim kümesinde olan çiftlerin %10'u rastgele ayrılıp S0 testi olur; bir ilacı test, diğeri eğitim kümesinde olan çiftler S1 testi; iki ilacı da test kümesinde olan çiftler S2 testi olur. Doğrulama kümesindeki ilaçları içeren çiftler	Senaryo: S0 (iki ilaç da eğitimde) / S1 (biri yeni) / S2 (ikisi de yeni)	Test çifti sayısı (ortalama)	Hata çubuğu: 5 seed'in standart sapması	Tam cold-start test kümesi kaç çift olur ve 86 tipin kaçını içerir? 3. haftadaki protokol bu sayılara göre yazılır	

Kod	Grafik	Veri	x ekseni	y ekseni	Renk / ölçek	Cevaplanacak soru	Öncelik
		doğrulamaya gider. 5 farklı seed					
T07	Gruplu çubuk	TDC'nin rastgele bölmesi, `frac=[0.7, 0.1, 0.2]`, seed 42	En sık 20 tip	O tipin küme içindeki oranı	Renk: eğitim / doğrulama / test	Rastgele bölmede sınıf oranları korunuyor mu?	Opsiyonel

D. TWOSIDES (opsiyonel)

Kod	Grafik	Veri	x ekseni	y ekseni	Renk / ölçek	Cevaplanacak soru	Öncelik
W01	Çubuk	TDC TWOSIDES, yan etki başına çift sayısı	1.317 yan etki, azalan sırada	Çift sayısı	y log	Yan etki etiketleri ne kadar dengesiz?	Opsiyonel
W02	Histogram	TDC TWOSIDES, çift başına yan etki sayısı	Yan etki sayısı	Çift sayısı	—	Bir çift ortalama kaç etiket taşıyor?	Opsiyonel

Hafta sonu teslim kontrol listesi

Toplantıdan en az bir gün önce aşağıdakilerin tümü depoda olmalıdır. Bir madde yapılamadıysa nedeni `docs/acik_sorular.md` dosyasına yazılır.

Veri dosyaları (depoda değil, paylaşılan klasörde)

- ☐ `data/interim/urun.csv`
- ☐ `data/interim/urun_etken.csv`
- ☐ `data/interim/etken_madde.csv`
- ☐ `data/interim/ddinter_ilac.csv`
- ☐ `data/interim/etkilesim.csv`
- ☐ `data/interim/atc_celiski_siniflari.csv`
- ☐ `data/interim/drugbank_tip_aciklama.csv`

Kod (depoda)

- ☐ `src/normalize.py`
- ☐ `notebooks/01` – `07` (`08` zaman kalırsa), baştan sona hatasız çalışıyor
- ☐ `config/tuz_listesi.txt`, `config/tr_en_kurallar.csv`

Belgeler (depoda, `docs/`)

- ☐ `esleme_raporu.md`: "Etken maddelerin %X'i, ürünlerin %Y'si DDInter'da bulunuyor" cümlesi ve tabloları
- ☐ `ddinter_kayip_analizi.md`: tekrar sonrası sayılar, kayıp oranı, 10 çiftlik web kontrolü
- ☐ `eda_raporu.md`: özet tablolar, opsiyonel olmayan tüm grafikler ve yorumları
- ☐ `uctan_uca_test.md`: üç senaryonun sonuçları
- ☐ `atc_celiski_kontrol.md`: 20 ürünlük elle kontrol
- ☐ Araç testi sonuçları (gerçek etkileşim kontrol araçlarıyla)
- ☐ EmerGNN ve DDI-Ben özetleri, literatür sonuç tablosu
- ☐ `lisanslar.md` güncellemesi
- ☐ Kapsam kararı için tek sayfalık karşılaştırma ve ekibin önerisi
- ☐ `acik_sorular.md`

Toplantıda karar verilecekler

1. Birincil kullanıcı: hasta/hasta yakını mı, eczacı mı?
2. DDInter eşleşme oranına göre kapsam: tüm etken maddeler mi, en sık 200–300 etken madde mi?
3. Elle eşlemenin 3. haftada ne kadar devam edeceği
4. DDInter'dan yanıt gelmediyse eksik gruplar için izlenecek yol
5. T06 sonuçlarına göre 3. haftadaki değerlendirme protokolünün bölme oranları

Kaynaklar ve doğrulama

Belgedeki ilaç adları, ATC kodları, lisanslar, araç adları ve kod örnekleri Oct 13, 2026 tarihinde aşağıdaki sayfalarla kontrol edildi. Kontrol sonucunda düzeltilenler: ürün adları Türkiye'deki resmî yazımına getirildi ("FILM KAPLI TABLET"), Klacid ürün örnekleri, PubChem SMILES özellik adları ve paracetamol/acetaminophen örneği. Ayrıca planın kendi içindeki tutarsızlıklar düzeltildi: ATC adı sözlüğü, kombinasyon kodları, Türkçe büyük/küçük harf katlaması, tuz eklerinin tam sözcük olarak atılması, DDInter'daki çoklu ATC kodları T06'daki S0/S1/S2 tanımı, kural 4'ün uygulanma sırası, SKRS barkod tekilleştirmesi, E01'in karşılaştırma kümesi, Yol A ve B'nin ATC adı kaynağı ve diyagramdaki bağımlılık oku.

Doğrulanmayanlar (öğrenci raporlarından alındı, ekip kendi verisinde yeniden sayacak): DDInter, TDC ve TİTCK dosyalarına ait tüm sayılar; MRCGNN oranlarının tip yüzdesi olduğu yalnızca aritmetikle kontrol edildi (86 tipin 5/18/10/12/41'i). DDInter'ın klaritromisine A02BD kodlarını atayıp atamadığı kontrol edilmedi; A02BD grubunun klaritromisinli kombinasyonlar içerdiği WHO ATC/DDD Index – A02BD sayfasından doğrulandı. Amlodipin (C08CA01) ve valsartan (C09CA03) ATC kodları ayrıca kaynakla kontrol edilmedi.

İlaç adları ve ATC kodları

- WHO ATC/DDD Index – M01AE: dexketoprofen M01AE17
- WHO Temel İlaç Listesi – Warfarin: B01AA03
- C09DB01 – Valsartan and Amlodipine (WHO kaynaklı)
- ARVELES 25 mg film kaplı tablet KÜB (TİTCK): deksketoprofen trometamol
- COUMADIN 5 mg tablet KÜB, farmakolojik özellikler: varfarin sodyum, B01AA03
- KLACID 500 mg film kaplı tablet ve KLACID MR 500: klaritromisin, J01FA09

Veri kaynakları

- DDInter – indirme sayfası: 8 dosya (A, B, D, H, L, P, R, V)
- DDInter – kullanım koşulları: CC BY-NC-SA 4.0; bir etkileşimin bulunmaması etkileşim olmadığı anlamına gelmez
- DDInter 2.0 – indirme sayfası: aynı 8 dosya
- DDInter 2.0 – Acetaminophen (DDInter14): ilaç sayfasında ATC ve SMILES
- TDC – Drug-Drug Interaction: DrugBank DDI, TWOSIDES, `get_label_map`, lisans metinleri
- TDC – Dataset Splits: cold-start bölmesi, varsayılan %70/%10/%20
- DrugBank – sürüm sayfası: akademik indirmelerin geçici olarak durdurulduğu duyurusu
- PubChem – programatik erişim: saniyede en fazla 5 istek
- PubChem SMILES özellik adlarının değişmesi (ikincil kaynak)

Etkileşim kontrol araçları

- WebMD Drug Interaction Checker
- Etkileşim kontrol araçları karşılaştırması (Medscape için ücretsiz kayıt gerekliliği)

Literatür

- MRCGNN (AAAI 2023)
- EmerGNN (Nature Computational Science) – arXiv sürümü: S1 ve S2 senaryoları
- DDI-Ben (Bioinformatics, 2025): dağılım değişimi altında yeni ilaç DDI tahmini
- OpenDDI (arXiv 2602.00539)